

Санкт-Петербургский политехнический университет
Петра Великого

Физико-механический институт
Высшая школа прикладной математики и физики

Отчёт
по лабораторным работам №5-8
по дисциплине
«Математическая статистика»

Выполнил студент:
Чевыкалов Григорий Андреевич
Группа: 5030102/90201
Проверил:
к.ф.-м.н., доцент
Баженов Александр Николаевич

Санкт-Петербург
2022

Содержание

1	Постановка задачи	5
2	Теория	6
2.1	Двумерное нормальное распределение	6
2.2	Корреляционный момент (ковариация) и коэффициент корреляции	6
2.3	Выборочные коэффициенты корреляции	6
2.3.1	Выборочный коэффициент корреляции Пирсона	6
2.3.2	Выборочный квадрантный коэффициент корреляции	6
2.3.3	Выборочный коэффициент ранговой корреляции Спирмена	7
2.4	Эллипсы рассеивания	7
2.5	Простая линейная регрессия	7
2.5.1	Модель простой линейной регрессии	7
2.5.2	Метод наименьших квадратов	7
2.5.3	Расчётные формулы для МНК-оценок	7
2.6	Робастные оценки коэффициентов линейной регрессии	8
2.7	Метод максимального правдоподобия	8
2.8	Проверка гипотезы о законе распределения генеральной совокупности. Метод хи-квадрат	9
2.9	Доверительные интервалы для параметров нормального распределения	9
2.9.1	Доверительный интервал для математического ожидания m нормального распределения	9
2.9.2	Доверительный интервал для среднего квадратического отклонения σ нормального распределения	10
2.10	Доверительные интервалы для математического ожидания m и среднего квадратического отклонения σ произвольного распределения при большом объёме выборки. Асимптотический подход	10
2.10.1	Доверительный интервал для математического ожидания m произвольной генеральной совокупности при большом объёме выборки	10
2.10.2	Доверительный интервал для среднего квадратического отклонения σ произвольной генеральной совокупности при большом объёме выборки	10
3	Реализация	11
4	Результаты	11
4.1	Выборочные коэффициенты корреляции	11
4.2	Эллипсы рассеивания	12
4.3	Оценки коэффициентов линейной регрессии	16
4.3.1	Выборка без возмущений	16
4.3.2	Выборка с возмущениями	17
4.4	Проверка гипотезы о законе распределения генеральной совокупности. Метод хи-квадрат	18
4.5	Доверительные интервалы для параметров нормального распределения	19
4.6	Доверительные интервалы для параметров произвольного распределения. Асимптотический подход	19
4.7	Сравнение результатов 4.5 и 4.6. Графическое представление	20

5	Обсуждение	21
5.1	Выборочные коэффициенты корреляции	21
5.2	Оценки коэффициентов линейной регрессии	21
5.3	Проверка гипотезы о законе распределения генеральной совокупности. Метод хи-квадрат	22
5.4	Доверительные интервалы для параметров распределения	22
6	Ссылка на репозиторий	22
	Список литературы	23

Список иллюстраций

1	Двумерное нормальное распределение, $n = 20$	13
2	Двумерное нормальное распределение, $n = 60$	14
3	Двумерное нормальное распределение, $n = 100$	15
4	Смесь нормальных распределений	16
5	Выборка без возмущений	17
6	Выборка с возмущениями	18
7	Гистограмма распределения	20
8	Полученные интервалы	21

Список таблиц

1	Двумерное нормальное распределение, $n = 20$	11
2	Двумерное нормальное распределение, $n = 60$	11
3	Двумерное нормальное распределение, $n = 100$	12
4	Смесь нормальных распределений	12
5	Вычисление χ^2_B при проверке гипотезы H_0 о нормальном законе распределения $N(x, \hat{\mu}, \hat{\sigma})$	18
6	Вычисление χ^2_B при проверке гипотезы H_0 о законе распределения $L(x, \hat{\mu}, \hat{\sigma})$, $n = 20$	19
7	Доверительные интервалы для параметров нормального распределения	19
8	Доверительные интервалы для параметров произвольного распределения. Асимптотический подход	19

1 Постановка задачи

1. Сгенерировать двумерные выборки размерами 20, 60, 100 для нормального двумерного распределения $N(x, y, 0, 0, 1, 1, \rho)$. Коэффициент корреляции ρ взять равным 0, 0.5, 0.9. Каждая выборка генерируется 1000 раз и для неё вычисляются: среднее значение, среднее значение квадрата и дисперсия коэффициентов корреляции Пирсона, Спирмена и квадрантного коэффициента корреляции. Повторить все вычисления для смеси нормальных распределений:

$$f(x, y) = 0.9N(x, y, 0, 0, 1, 1, 0.9) + 0.1N(x, y, 0, 0, 10, 10, -0.9) \quad (1)$$

Изобразить сгенерированные точки на плоскости и нарисовать эллипс равновероятности.

2. Найти оценки коэффициентов линейной регрессии $y_i = a + bx_i + e_i$, используя 20 точек на отрезке $[-1.8; 2]$ с равномерным шагом равным 0.2. Ошибку e_i считать нормально распределённой с параметрами $(0, 1)$. В качестве эталонной зависимости взять $y_i = 2 + 2x_i + e_i$. При построении оценок коэффициентов использовать два критерия: критерий наименьших квадратов и критерий наименьших модулей. Прodelать то же самое для выборки, у которой в значения y_1 и y_{20} вносятся возмущения 10 и -10.
3. Сгенерировать выборку объёмом 100 элементов для нормального распределения $N(x, 0, 1)$. По сгенерированной выборке оценить параметры μ и σ нормального закона методом максимального правдоподобия. В качестве основной гипотезы H_0 будем считать, что сгенерированное распределение имеет вид $N(x, \hat{\mu}, \hat{\sigma})$. Проверить основную гипотезу, используя критерий согласия χ^2 . В качестве уровня значимости взять $\alpha = 0.05$. Привести таблицу вычислений χ^2 . Исследовать точность (чувствительность) критерия χ^2 — сгенерировать выборки равномерного распределения и распределения Лапласа малого объёма (например, 20 элементов). Проверить их на нормальность.
4. Для двух выборок размерами 20 и 100 элементов, сгенерированных согласно нормальному закону $N(x, 0, 1)$, для параметров положения и масштаба построить асимптотически нормальные интервальные оценки на основе точечных оценок метода максимального правдоподобия и классические интервальные оценки на основе статистик χ^2 и Стьюдента. В качестве параметра надёжности взять $\gamma = 0.95$.

2 Теория

2.1 Двумерное нормальное распределение

Двумерная случайная величина (X, Y) называется распределённой нормально (или просто нормальной), если её плотность вероятности определена формулой

$$N(x, y, \bar{x}, \bar{y}, \sigma_x, \sigma_y, \rho) = \frac{1}{2\pi\sigma_x\sigma_y\sqrt{1-\rho^2}} \times \exp\left\{-\frac{1}{2(1-\rho^2)} \left[\frac{(x-\bar{x})^2}{\sigma_x^2} - 2\rho\frac{(x-\bar{x})(y-\bar{y})}{\sigma_x\sigma_y} + \frac{(y-\bar{y})^2}{\sigma_y^2} \right]\right\} \quad (2)$$

Компоненты X, Y двумерной нормальной случайной величины также распределены нормально с математическими ожиданиями \bar{x}, \bar{y} и средними квадратическими отклонениями σ_x, σ_y соответственно [1, с. 133-134]. Параметр ρ называется коэффициентом корреляции.

2.2 Корреляционный момент (ковариация) и коэффициент корреляции

Корреляционный момент, иначе ковариация, двух случайных величин X и Y :

$$K = cov(X, Y) = M[(X - \bar{x})(Y - \bar{y})] \quad (3)$$

Коэффициент корреляции ρ двух случайных величин X и Y :

$$\rho = \frac{K}{\sigma_x\sigma_y} \quad (4)$$

2.3 Выборочные коэффициенты корреляции

2.3.1 Выборочный коэффициент корреляции Пирсона

Выборочный коэффициент корреляции Пирсона:

$$r = \frac{\frac{1}{n} \sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\frac{1}{n} \sum (x_i - \bar{x})^2 \frac{1}{n} \sum (y_i - \bar{y})^2}} = \frac{K}{s_X s_Y}, \quad (5)$$

где K, s_X^2, s_Y^2 — выборочные ковариация и дисперсии с.в. X и Y [1, с. 535].

2.3.2 Выборочный квадрантный коэффициент корреляции

Выборочный квадрантный коэффициент корреляции:

$$r_Q = \frac{(n_1 + n_3) - (n_2 + n_4)}{n}, \quad (6)$$

где n_1, n_2, n_3, n_4 — количества точек с координатами x_i, y_i , попавшими соответственно в I, II, III, IV квадранты декартовой системы с осями $x' = x - med_x, y' = y - med_y$ и с центром в точке с координатами (med_x, med_y) [1, с. 539].

2.3.3 Выборочный коэффициент ранговой корреляции Спирмена

Обозначим ранги, соответствующие значениям переменной X , через u , а ранги, соответствующие значениям переменной Y , — через v .

Выборочный коэффициент ранговой корреляции Спирмена определяется как выборочный коэффициент корреляции Пирсона между рангами u , v переменных X , Y :

$$r_S = \frac{\frac{1}{n} \sum (u_i - \bar{u})(v_i - \bar{v})}{\sqrt{\frac{1}{n} \sum (u_i - \bar{u})^2 \frac{1}{n} \sum (v_i - \bar{v})^2}}, \quad (7)$$

где $\bar{u} = \bar{v} = \frac{1+2+\dots+n}{n} = \frac{n+1}{2}$ — среднее значение рангов [1, с. 540-541].

2.4 Эллипсы рассеивания

Уравнение проекции эллипса рассеивания на плоскость xOy :

$$\frac{(x - \bar{x})^2}{\sigma_x^2} - 2\rho \frac{(x - \bar{x})(y - \bar{y})}{\sigma_x \sigma_y} + \frac{(y - \bar{y})^2}{\sigma_y^2} = const \quad (8)$$

Центр эллипса находится в точке с координатами (\bar{x}, \bar{y}) ; что касается направления осей симметрии эллипса, то они составляют с осью Ox углы, определяемые уравнением

$$tg(2\alpha) = \frac{2\rho\sigma_x\sigma_y}{\sigma_x^2 - \sigma_y^2} \quad (9)$$

2.5 Простая линейная регрессия

2.5.1 Модель простой линейной регрессии

Регрессионную модель описания данных называют простой линейной регрессией, если

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, i = 1..n \quad (10)$$

где x_1, \dots, x_n — заданные числа (значения фактора); y_1, \dots, y_n — наблюдаемые значения отклика; $\varepsilon_1, \dots, \varepsilon_n$ — независимые, нормально распределенные $N(0, \sigma)$ с нулевым математическим ожиданием и одинаковой (неизвестной) дисперсией случайные величины (ненаблюдаемые); β_0, β_1 — неизвестные параметры, подлежащие оцениванию.

2.5.2 Метод наименьших квадратов

Метод наименьших квадратов (МНК):

$$Q(\beta_0, \beta_1) = \sum_{i=1}^n \varepsilon_i^2 = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2 \rightarrow \min_{\beta_0, \beta_1} \quad (11)$$

2.5.3 Расчётные формулы для МНК-оценок

МНК-оценки параметров $\hat{\beta}_0, \hat{\beta}_1$:

$$\hat{\beta}_1 = \frac{\bar{x}\bar{y} - \bar{x} \cdot \bar{y}}{\bar{x}^2 - (\bar{x})^2} \quad (12)$$

$$\hat{\beta}_0 = \bar{y} - \bar{x}\hat{\beta}_1 \quad (13)$$

2.6 Робастные оценки коэффициентов линейной регрессии

Метод наименьших модулей:

$$\sum_{i=1}^n |y_i - \beta_0 - \beta_1 x_i| \rightarrow \min_{\beta_0, \beta_1} \quad (14)$$

$$\hat{\beta}_{1R} = r_Q \frac{q_y^*}{q_x^*}, \quad (15)$$

$$\hat{\beta}_{0R} = med y - \hat{\beta}_{1R} med x, \quad (16)$$

$$r_Q = \frac{1}{n} \sum_{i=1}^n sgn(x_i - med x) sgn(y_i - med y), \quad (17)$$

$$q_y^* = \frac{y_{(j)} - y_{(l)}}{k_q(n)}, \quad q_x^* = \frac{x_{(j)} - x_{(l)}}{k_q(n)}. \quad (18)$$

$$l = \begin{cases} \lfloor \frac{n}{4} \rfloor + 1 & \text{при } \frac{n}{4} \text{ дробном,} \\ \frac{n}{4} & \text{при } \frac{n}{4} \text{ целом.} \end{cases}$$

$$j = n - l + 1$$

$$sgn(z) = \begin{cases} 1 & \text{при } z > 0 \\ 0 & \text{при } z = 0 \\ -1 & \text{при } z < 0 \end{cases}$$

Уравнение регрессии здесь имеет вид:

$$y = \hat{\beta}_{0R} + \hat{\beta}_{1R} x. \quad (19)$$

2.7 Метод максимального правдоподобия

$L(x_1, \dots, x_n, \theta)$ — функция правдоподобия (ФП), представляющая собой совместную плотность вероятности независимых с.в. x_1, \dots, x_n и рассматриваемая как функция неизвестного параметра θ :

$$L(x_1, \dots, x_n, \theta) = f(x_1, \theta) f(x_2, \theta) \dots f(x_n, \theta) \quad (20)$$

Оценка максимального правдоподобия:

$$\hat{\theta}_m = \arg \max_{\theta} L(x_1, \dots, x_n, \theta) \quad (21)$$

Система уравнений правдоподобия (в случае дифференцируемости функции правдоподобия):

$$\frac{\partial L}{\partial \theta_k} = 0 \text{ или } \frac{\partial \ln L}{\partial \theta_k} = 0, k = 1, \dots, m. \quad (22)$$

2.8 Проверка гипотезы о законе распределения генеральной совокупности. Метод хи-квадрат

Выдвинута гипотеза H_0 о генеральном законе распределения с функцией распределения $F(x)$.

Рассматриваем случай, когда гипотетическая функция распределения $F(x)$ не содержит неизвестных параметров.

Правило проверки гипотезы о законе распределения по методу χ^2 .

1. Выбираем уровень значимости α .
2. По таблице [3, с. 358] находим квантиль $\chi^2_{1-\alpha}(k-1)$ распределения хи-квадрат с $k-1$ степенями свободы порядка $1-\alpha$.
3. С помощью гипотетической функции распределения $F(x)$ вычисляем вероятности $p_i = P(X \in \Delta_i)$, $i = 1, \dots, k$.
4. Находим частоты n_i попадания элементов выборки в подмножества Δ_i , $i = 1, \dots, k$.
5. Вычисляем выборочное значение статистики критерия χ^2 :

$$\chi_B^2 = \sum_{i=1}^k \frac{(n_i - np_i)^2}{np_i}. \quad (23)$$

6. Сравниваем χ_B^2 и квантиль $\chi^2_{1-\alpha}(k-1)$.
 - Если $\chi_B^2 < \chi^2_{1-\alpha}(k-1)$, то гипотеза H_0 на данном этапе проверки принимается.
 - Если $\chi_B^2 \geq \chi^2_{1-\alpha}(k-1)$, то гипотеза H_0 отвергается, выбирается одно из альтернативных распределений, и процедура проверки повторяется.

2.9 Доверительные интервалы для параметров нормального распределения

2.9.1 Доверительный интервал для математического ожидания m нормального распределения

Дана выборка (x_1, x_2, \dots, x_n) объёма n из нормальной генеральной совокупности. На её основе строим выборочное среднее \bar{x} и выборочное среднее квадратическое отклонение s .

Параметры m и σ нормального распределения неизвестны.

Доверительный интервал для m с доверительной вероятностью $\gamma = 1 - \alpha$:

$$\begin{aligned} P\left(\bar{x} - \frac{sx}{\sqrt{n-1}} < m < \bar{x} + \frac{sx}{\sqrt{n-1}}\right) &= 2F_T(x) - 1 = 1 - \alpha, \\ P\left(\bar{x} - \frac{st_{1-\alpha/2}(n-1)}{\sqrt{n-1}} < m < \bar{x} + \frac{st_{1-\alpha/2}(n-1)}{\sqrt{n-1}}\right) &= 1 - \alpha, \end{aligned} \quad (24)$$

2.9.2 Доверительный интервал для среднего квадратического отклонения σ нормального распределения

Дана выборка (x_1, x_2, \dots, x_n) объёма n из нормальной генеральной совокупности. На её основе строим выборочную дисперсию s^2 . Параметры m и σ нормального распределения неизвестны. Доказано, что случайная величина ns^2/σ^2 распределена по закону χ^2 с $n - 1$ степенями свободы.

Доверительный интервал для σ с доверительной вероятностью $\gamma = 1 - \alpha$:

$$P \left(\frac{s\sqrt{n}}{\sqrt{\chi_{1-\alpha/2}^2(n-1)}} < \sigma < \frac{s\sqrt{n}}{\sqrt{\chi_{\alpha/2}^2(n-1)}} \right) = 1 - \alpha, \quad (25)$$

2.10 Доверительные интервалы для математического ожидания m и среднего квадратического отклонения σ произвольного распределения при большом объёме выборки. Асимптотический подход

При большом объёме выборки для построения доверительных интервалов может быть использован асимптотический метод на основе центральной предельной теоремы.

2.10.1 Доверительный интервал для математического ожидания m произвольной генеральной совокупности при большом объёме выборки

Предполагаем, что исследуемое генеральное распределение имеет конечные математическое ожидание m и дисперсию σ^2 .

$u_{1-\alpha/2}$ — квантиль нормального распределения $N(0,1)$ порядка $1 - \alpha/2$.

Доверительный интервал для m с доверительной вероятностью $\gamma = 1 - \alpha$:

$$P \left(\bar{x} - \frac{su_{1-\alpha/2}}{\sqrt{n}} < m < \bar{x} + \frac{su_{1-\alpha/2}}{\sqrt{n}} \right) \approx \gamma, \quad (26)$$

2.10.2 Доверительный интервал для среднего квадратического отклонения σ произвольной генеральной совокупности при большом объёме выборки

Предполагаем, что исследуемая генеральная совокупность имеет конечные первые четыре момента.

$u_{1-\alpha/2}$ — квантиль нормального распределения $N(0,1)$ порядка $1 - \alpha/2$.

$E = \frac{\mu_4}{\sigma^4} - 3$ — эксцесс генерального распределения, $e = \frac{m_4}{s^4} - 3$ — выборочный эксцесс;

$m_4 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^4$ — четвёртый выборочный центральный момент.

$$s(1 + U)^{-1/2} < \sigma < s(1 - U)^{-1/2} \quad (27)$$

или

$$s(1 - 0.5U) < \sigma < s(1 + 0.5U), \quad (28)$$

где $U = u_{1-\alpha/2} \sqrt{(e + 2)/n}$.

Формулы (27) или (28) дают доверительный интервал для σ с доверительной вероятностью $\gamma = 1 - \alpha$ [1, с. 461-462].

Замечание. Вычисления по формуле (27) дают более надёжный результат, так как в ней меньше грубых приближений.

3 Реализация

Лабораторная работа выполнена на языке программирования Python (v3.10.2) с использованием редактора Visual Studio Code (расширение Python v2022.2.1924087327). Для реализации использовались библиотеки numpy (v1.22.3), matplotlib (v3.5.1), scipy (v1.8.0). Отчет подготовлен с использованием TeXstudio и TeX Live.

4 Результаты

4.1 Выборочные коэффициенты корреляции

$\rho = 0$ (4)	r (5)	r_Q (6)	r_S (7)
$E(z)$	-0.011	-0.012	-0.012
$E(z^2)$	0.055	0.055	0.054
$D(z)$	0.235	0.234	0.231
$\rho = 0.5$ (4)	r (5)	r_Q (6)	r_S (7)
$E(z)$	0.477	0.451	0.323
$E(z^2)$	0.259	0.24	0.151
$D(z)$	0.179	0.19	0.215
$\rho = 0.9$ (4)	r (5)	r_Q (6)	r_S (7)
$E(z)$	0.895	0.865	0.695
$E(z^2)$	0.804	0.754	0.512
$D(z)$	0.05	0.071	0.172

Таблица 1: Двумерное нормальное распределение, $n = 20$

$\rho = 0$ (4)	r (5)	r_Q (6)	r_S (7)
$E(z)$	-0.001	0.001	0.001
$E(z^2)$	0.018	0.017	0.017
$D(z)$	0.134	0.132	0.131
$\rho = 0.5$ (4)	r (5)	r_Q (6)	r_S (7)
$E(z)$	0.495	0.474	0.333
$E(z^2)$	0.255	0.235	0.126
$D(z)$	0.098	0.103	0.122
$\rho = 0.9$ (4)	r (5)	r_Q (6)	r_S (7)
$E(z)$	0.898	0.882	0.708
$E(z^2)$	0.807	0.78	0.51
$D(z)$	0.026	0.033	0.091

Таблица 2: Двумерное нормальное распределение, $n = 60$

$\rho = 0$ (4)	r (5)	r_Q (6)	r_S (7)
$E(z)$	0.003	0.002	0.002
$E(z^2)$	0.01	0.01	0.01
$D(z)$	0.099	0.099	0.101
$\rho = 0.5$ (4)	r (5)	r_Q (6)	r_S (7)
$E(z)$	0.495	0.476	0.335
$E(z^2)$	0.251	0.233	0.122
$D(z)$	0.079	0.084	0.1
$\rho = 0.9$ (4)	r (5)	r_Q (6)	r_S (7)
$E(z)$	0.898	0.885	0.705
$E(z^2)$	0.807	0.784	0.503
$D(z)$	0.02	0.025	0.071

Таблица 3: Двумерное нормальное распределение, $n = 100$

$n = 20$	r (5)	r_Q (6)	r_S (7)
$E(z)$	0.803	0.773	0.597
$E(z^2)$	0.653	0.609	0.391
$D(z)$	0.087	0.106	0.187
$n = 60$	r (5)	r_Q (6)	r_S (7)
$E(z)$	0.809	0.788	0.594
$E(z^2)$	0.656	0.623	0.364
$D(z)$	0.045	0.055	0.106
$n = 100$	r (5)	r_Q (6)	r_S (7)
$E(z)$	0.809	0.791	0.597
$E(z^2)$	0.656	0.628	0.363
$D(z)$	0.035	0.042	0.081

Таблица 4: Смесь нормальных распределений

4.2 Эллипсы рассеивания

Для уравнения эллипса выбиралась константа $const = 9$.

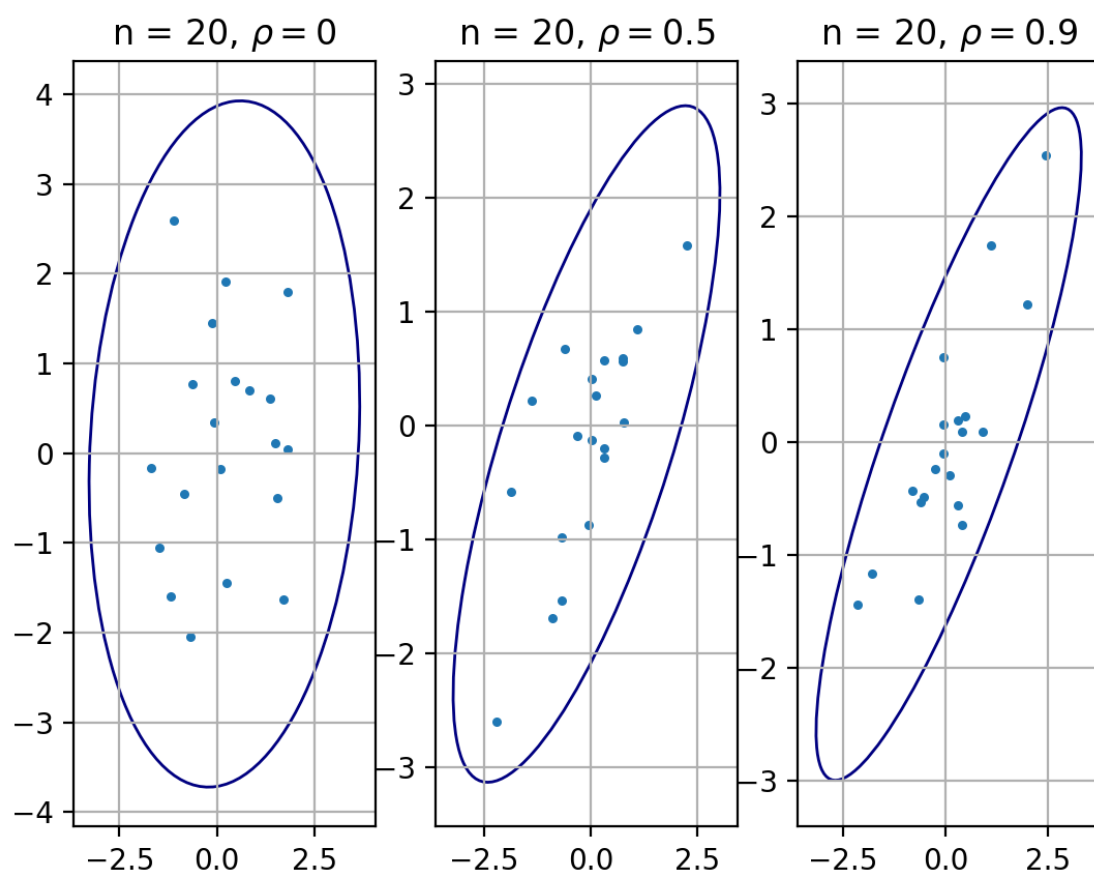


Рис. 1: Двумерное нормальное распределение, $n = 20$

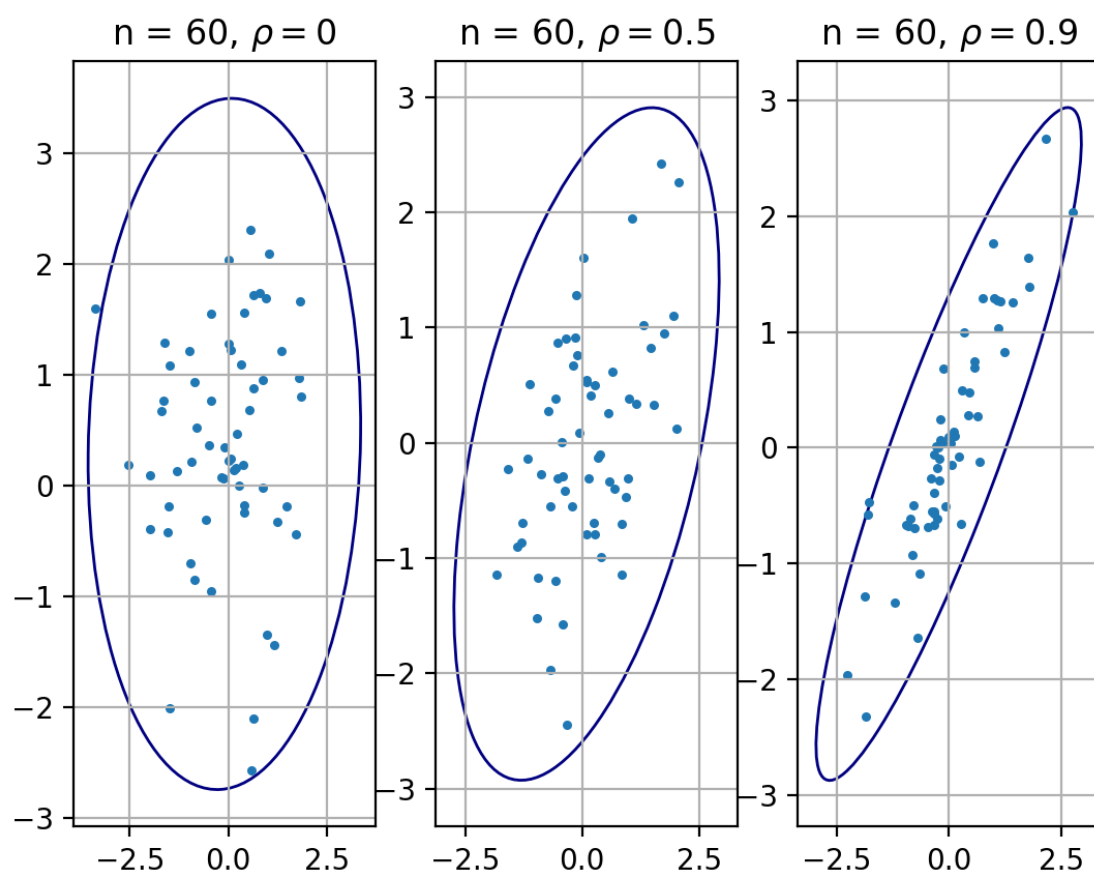


Рис. 2: Двумерное нормальное распределение, $n = 60$




Рис. 3: Двумерное нормальное распределение, $n = 100$




Рис. 4: Смесь нормальных распределений

4.3 Оценки коэффициентов линейной регрессии

4.3.1 Выборка без возмущений

1. Критерий наименьших квадратов: $\hat{a} \approx 1.89$, $\hat{b} \approx 1.91$
2. Критерий наименьших модулей: $\hat{a} \approx 2.00$, $\hat{b} \approx 1.70$




Рис. 5: Выборка без возмущений

4.3.2 Выборка с возмущениями

1. Критерий наименьших квадратов: $\hat{a} \approx 2.03$, $\hat{b} \approx 0.48$
2. Критерий наименьших модулей: $\hat{a} \approx 1.96$, $\hat{b} \approx 1.66$




Рис. 6: Выборка с возмущениями

4.4 Проверка гипотезы о законе распределения генеральной совокупности. Метод хи-квадрат

Метод максимального правдоподобия: $\hat{\mu} \approx -0.08, \hat{\sigma} \approx 0.96$

i	Границы Δ_i	n_i	p_i	np_i	$n_i - np_i$	$\frac{(n_i - np_i)^2}{np_i}$
1	$-\infty, -3.08$	0.00	0.0009	0.09	-0.09	0.09
2	$-3.08, -1.88$	4.00	0.0291	2.91	1.09	0.41
3	$-1.88, -0.68$	23.00	0.2353	23.53	-0.53	0.01
4	$-0.68, 0.52$	43.00	0.4695	46.95	-3.95	0.33
5	$0.52, 1.72$	27.00	0.2353	23.53	3.47	0.51
6	$1.72, 2.92$	3.00	0.0291	2.91	0.09	0.00
7	$2.92, +\infty$	0.00	0.0009	0.09	-0.09	0.09
Σ	—	100.00	1.0000	100.00	0.00	1.44

Таблица 5: Вычисление χ_B^2 при проверке гипотезы H_0 о нормальном законе распределения $N(x, \hat{\mu}, \hat{\sigma})$

Видим, что $\chi_B^2 < \chi_{0.95}^2 \approx 14.1$, следовательно, гипотезу полагаем верной.

i	Границы Δ_i	n_i	p_i	np_i	$n_i - np_i$	$\frac{(n_i - np_i)^2}{np_i}$
1	$-\infty, -3.16$	0.00	0.0000	0.00	-0.00	0.00
2	-3.16, -1.96	0.00	0.0009	0.02	-0.02	0.02
3	-1.96, -0.76	5.00	0.1475	2.95	2.05	1.43
4	-0.76, 0.44	13.00	0.7033	14.07	-1.07	0.08
5	0.44, 1.64	2.00	0.1475	2.95	-0.95	0.31
6	1.64, 2.84	0.00	0.0009	0.02	-0.02	0.02
7	2.84, $+\infty$	0.00	0.0000	0.00	-0.00	0.00
Σ	—	20.00	1.0000	20.00	0.00	1.85

Таблица 6: Вычисление χ_B^2 при проверке гипотезы H_0 о законе распределения $L(x, \hat{\mu}, \hat{\sigma})$, $n = 20$

Видим, что $\chi_B^2 < \chi_{0.95}^2 \approx 14.1$, следовательно, гипотеза принимается и в этот раз.

4.5 Доверительные интервалы для параметров нормального распределения

n = 20	m	σ
	$-0.38 < m < 0.75$	$0.88 < \sigma < 1.69$
n = 100	m	σ
	$-0.02 < m < 0.40$	$0.95 < \sigma < 1.25$

Таблица 7: Доверительные интервалы для параметров нормального распределения

4.6 Доверительные интервалы для параметров произвольного распределения. Асимптотический подход

n = 20	m	σ
	$-0.29 < m < 0.70$	$0.83 < \sigma < 2.73$
n = 100	m	σ
	$-0.02 < m < 0.40$	$0.90 < \sigma < 1.42$

Таблица 8: Доверительные интервалы для параметров произвольного распределения. Асимптотический подход

4.7 Сравнение результатов 4.5 и 4.6. Графическое представление

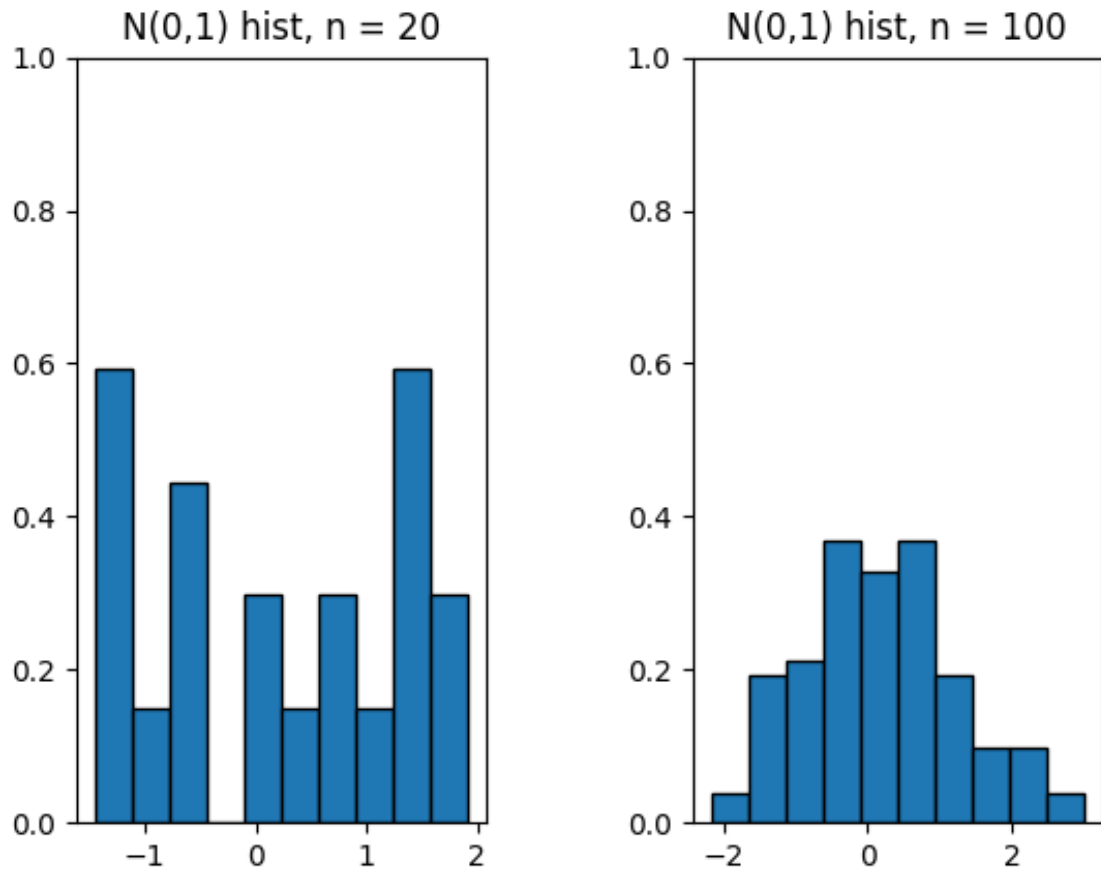


Рис. 7: Гистограмма распределения

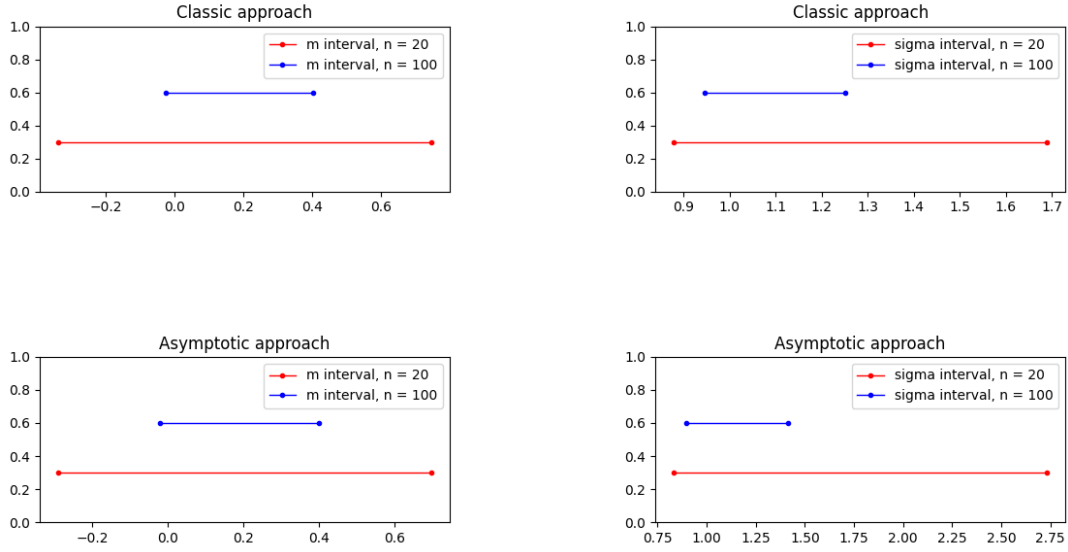


Рис. 8: Полученные интервалы

5 Обсуждение

5.1 Выборочные коэффициенты корреляции

Выборочный коэффициент корреляции Пирсона и квадрантный коэффициент достаточно точно описывают истинный коэффициент корреляции двумерной случайной величины (он попадает в доверительный интервал с центром в значении выборочного коэффициента и радиусом равным дисперсии).

- Для двумерного нормального распределения выборочные коэффициенты корреляции упорядочены следующим образом: $r_S < r_Q \leq r$;
- Для смеси распределений получили такую же картину: $r_S < r_Q \leq r$.
- Процент попавших элементов выборки в эллипс рассеивания (99%-ная доверительная область) примерно равен его теоретическому значению (99%).

5.2 Оценки коэффициентов линейной регрессии

По полученным результатам можно сказать, что критерий наименьших квадратов точнее оценивает коэффициенты линейной регрессии на выборки без возмущений.

Если же редкие возмущения присутствуют, тогда лучше использовать критерий наименьших модулей, поскольку он более устойчив.

5.3 Проверка гипотезы о законе распределения генеральной совокупности. Метод хи-квадрат

Заключаем, что гипотеза H_0 о нормальном законе распределения $N(x, \hat{\mu}, \hat{\sigma})$ на уровне значимости $\alpha = 0.05$ согласуется с выборкой для нормального распределения $N(x, 0, 1)$. Также видно, что для выборки сгенерированной по закону Лапласа гипотеза H_0 оказалась принята. То есть, при малых мощностях выборки критерий хи-квадрат не почувствовал разницы между нормально распределенной случайной величиной и распределенной по Лапласу. Это ожидаемый результат, ведь выборка довольно мала и законы схожи по форме. По исследованию на чувствительность видим, что при небольших объемах выборки уверенности в полученных результатах нет, критерий может ошибиться. Это обусловлено тем, что теорема Пирсона говорит про асимптотическое распределение, а при малых размерах выборки результат не будет получаться достоверным.

5.4 Доверительные интервалы для параметров распределения

- Генеральные характеристики ($m = 0$ и $\sigma = 1$) накрываются построенными доверительными интервалами.
- Также можно сделать вывод, что для большей выборки доверительные интервалы являются соответственно более точными, т.е. меньшими по длине.
- Кроме того, при большом объеме выборки асимптотические и классические оценки практически совпадают.

6 Ссылка на репозиторий

Репозиторий с исходным кодом: <https://github.com/gchevykalov/MathStat>.

Список литературы

- [1] Вероятностные разделы математики. Учебник для бакалавров технических направлений. /Под ред. Максимова Ю.Д. — Спб.: «Иван Федоров», 2001. — 592 с., илл.
- [2] Вентцель Е.С. Теория вероятностей: Учеб. для вузов. — 6-е изд. стер. — М.: Высш. шк., 1999. — 576 с.
- [3] Максимов Ю.Д. Математика. Теория и практика по математической статистике. Конспект-справочник по теории вероятностей : учеб. пособие /Ю.Д. Максимов; под ред. В.И. Антонова. — СПб. : Изд-во Политехн. ун-та, 2009. — 395 с. (Математика в политехническом университете).